

激光雷达点云特征表达研究进展

张振鑫^{1,2,3}, 刘艺博^{1,2,3}, 陈动⁴, 张立强⁵, 钟若飞^{1,2,3}, 徐宗霞^{1,2,3}, 韩友美⁶

(1. 首都师范大学北京成像技术高精尖创新中心, 北京 100048; 2. 首都师范大学资源环境与旅游学院, 北京 100048;

3. 首都师范大学三维数据获取与应用重点实验室, 北京 100048; 4. 南京林业大学土木工程学院, 江苏 南京 210037;

5. 北京师范大学遥感科学国家重点实验室, 北京 100875; 6. 北京市测绘设计研究院城市空间信息工程北京市重点实验室, 北京 100038)

摘要:激光雷达点云的特征表达是激光雷达点云分类识别的基础和关键,也是当前研究的重点和热点问题。该文对激光雷达点云特征表达的研究进展进行了探索和总结。首先,分别从基于点特征和基于对象特征的对比、稀疏编码特征、多层次特征及深度学习特征四方面进行论述,阐明了各种特征的特点,并验证了基于对象特征的优势;其次,对稀疏编码特征、多层次特征和深度学习特征进行了实验分析,得到稀疏编码特征及多层次特征在点云分类识别方面的特性及优势;最后,指出了激光雷达点云特征表达研究的未来发展趋势。该文可为激光雷达点云等空间数据的识别与结构化表达提供一定的借鉴和参考,也可为环境感知、自动驾驶等应用提供一定帮助。

关键词:激光雷达点云;特征表达;稀疏编码;深度学习;多层次;研究进展

中图分类号:P237 文献标识码:A 文章编号:1672-0504(2018)04-0033-07

0 引言

激光雷达(Light Detection and Ranging, LiDAR)点云分类与识别是地球空间信息科学领域的一个基础且重要的研究方向^[1],该研究不仅可用于电力^[2-4]、林业^[5]、道桥^[6-8]等传统行业,而且对以谷歌无人车为代表的无人驾驶^[9,10]等新兴行业也有重要作用。其中,激光雷达点云特征的高效构建是提高激光雷达点云分类精度的重要环节,点云分类算法精度与特征的高效性密切相关^[11]。

目前,激光雷达点云特征的表达有两种:1)从特征表达的基本单元划分^[12],包括基于点的特征^[13]和基于对象的特征,前者可减少对象构建的时间开销,但由于地物空间分布及表面形态的复杂性,该特征对形状等的变化较为敏感,不能得到稳定的分类识别结果;后者又可分为单层次对象特征^[12]和多层次(对象)特征^[14],主要通过将点的特征聚合或从对象的局部空间区域采用统计、学习等方式构建,能更好地克服点特征的不稳定性,增强分类的鲁棒性^[15]。2)从特征表达的层级划分^[16],主要分为低层次特征(如 SIFT (Scale Invariant Feature Transformation)^[17]、HOG (Histograms of Oriented Gradients)^[18]等)、中层次特征(如稀疏编码^[19]等)及高层次特征(如深度学习^[20]等)。其中,高层次特征的性能要优于中、低层次特征,但稳健的高层次特征的学习一般需要大量的训练数据。

随着机器学习,特别是深度学习理论^[21]的日渐发展与成熟,激光雷达点云更加稳定、高效特征的研究也有一定进展^[22,23]。本文主要针对激光雷达点云特征表达的研究进展及趋势进行探索,主要研究内容为:1)采用实验的方式,对基于点的特征和基于对象的特征进行深入分析和对比,同时,对稀疏编码特征的优势进行验证,并测试不同层次对象对分类结果的影响;2)对当前深度学习方法在激光雷达点云分类中的应用研究进行梳理,并通过实验对深度学习特征的性能进行测试,以期为激光雷达点云分类更深入的研究提供参考;3)对当前激光雷达点云特征构建的发展趋势进行预测与总结,探讨最新、最前沿的点云特征表达方法。

1 点特征与对象特征比较分析

基于点的特征主要有空间形状、统计、纹理及多回波特征等。空间形状特征包括法向量、主曲率和表面曲率等^[24],同时,由不同特征值组合形成的空间形状特征也常被用于激光雷达点云分类中^[25];此外,基于点的主成分分析(Principal Component Analysis, PCA)计算得到的协方差矩阵特征^[26],也是点形状特征的一种。点云的统计特征包括 Spin 图特

收稿日期:2017-07-15; 修回日期:2017-12-15

基金项目:国家自然科学基金项目(41701533、41371434);城市空间信息工程北京市重点实验室经费资助项目(2017205);二十一世纪空间技术应用股份有限公司2016年开放基金项目(21AT-2016-04)

作者简介:张振鑫(1986—),男,博士,讲师,从事激光雷达点云目标探测、分类等理论和应用研究。E-mail: zhangzhx@cnu.edu.cn

征^[14]及点分布统计特征等^[27],纹理特征常被用于彩色点云中^[28,29]。近年来,随着全波形数据的出现,点的全波形特征被构建出来,并在树种的分类中得到应用^[30]。在点的全波形特征基础上,将其与带有上下文信息的其他点特征相融合,并利用条件随机域(Conditional Random Field, CRF)对室外场景点云进行分类^[31]。

上述点特征是从局部范围内构建的算子,易受噪声的影响,稳定性不强;区域性特征算子在记录某点本身特征的同时,还记录周围其他点的特征,提高了局部点特征的稳定性和鲁棒性,如 Frome 等^[32]提出了三维形状纹理算子和波形形状纹理算子两种区域性点特征算子。研究显示,三维形状纹理算子对噪声具有很好的抑制作用,但该算子计算复杂、实用性不强,在复杂场景中,选择合适的支撑区域对场景的高质量识别至关重要。

点云对象特征主要在超体素(点集)的基础上实现。Lim 等^[33]结合通用尺度选择和体素化,通过迭代的方式将点云分割成超体素,计算出超体素的局部特征,并采用多尺度 CRF 的方式进行分类。该方法对体量较大物体(如树、建筑等)的标识效果较好,对体量较小的物体(如汽车等)未能充分顾及。由于体量较小的物体只包含少量点云,同时,由于局部遮挡,小物体的点云往往不完整,该方法在大、小物体同时存在时,分类效果受到一定影响。虽然超体素可减少计算中的数据单元,但其形成过程中的过分割明显增加了计算成本和时间开销^[34]。因此, Aijazi 等^[35]提出了基于连接链(link-chain)的超体素构建方法,该方法通过使用几何和局部特征描述算子构建对象及其特征,提高了特征构建效率。在基于体素重建的建筑模型方面, Truong 等^[36]采用垂直与水平网格体素的网格聚类技术提取物体外观形态特征,并结合飞体素(flying voxel)的方法对几何建筑进行建模。近年来,随着稀疏编码理论的出现,通过结合稀疏编码与潜狄利克雷分布(Latent Dirichlet Allocation, LDA)表达点集对象的特征,得到了更加稳定的点集对象特征表达结果^[37]。

为深入对比基于点特征与基于对象特征分类的差别,本文以机载 LiDAR 点云为例,对场景 1(表 1)采用基于对象特征的方法^[37]进行实验,并与基于 Spin 图^[14]和特征值^[25]联合的点特征以及基于深度学习的点特征^[38]的分类结果进行比较(表 2、图 1,彩图见封 2)。结果表明,基于对象特征的方法明显比基于 Spin 图和特征值联合的点特征分类结果稳定,

一定程度上克服了点特征对空间分布变化的敏感性;也比基于深度学习的点特征的分类结果(图 1d)更优,说明在训练数据较小时(表 1),深度学习难以得到稳健的点特征。

表 1 实验数据集
Table 1 The test datasets

	训练数据点的数目			测试数据点的数目		
	树木	建筑物	汽车	树木	建筑物	汽车
场景 1	68 802	37 128	5 380	213 990	200 549	7 816
场景 2	39 743	64 952	4 584	73 207	156 186	7 409

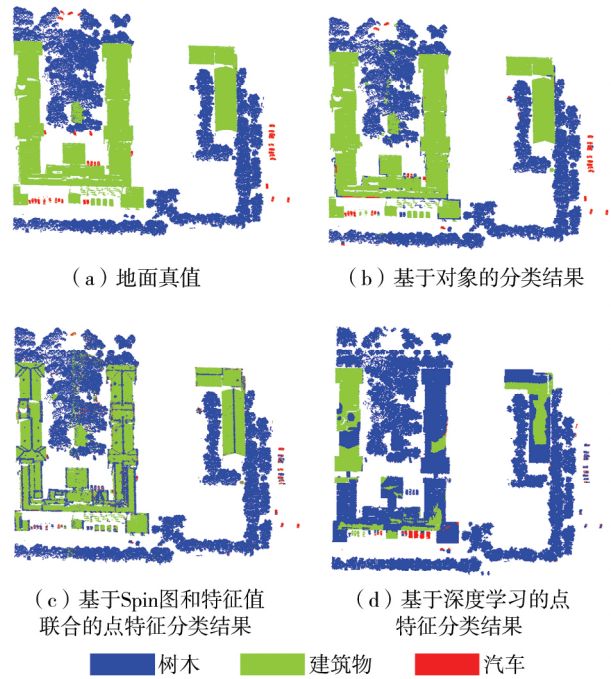


图 1 点特征、对象特征及深度学习特征的分类结果
Fig. 1 The classification results of the point-based feature, object-based feature and deep learning feature

表 2 分类结果的精度/召回率和准确度
Table 2 The precision/recall and accuracy of the classification results

场景 1	树木	建筑物	汽车	准确度
基于对象的特征	95.7/96.2	95.9/95.9	80.8/67.9	95.8
基于 Spin 图和特征值联合的点特征	85.7/92.9	92.0/83.8	56.9/54.7	87.9
基于深度学习的点特征	65.1/93.7	95.6/19.5	93.4/8.2	65.3

2 激光雷达点云的稀疏编码特征

稀疏编码采用字典中基的线性组合对输入信号(如点云特征等)进行稀疏表示,将这种稀疏表示称为稀疏编码特征^[39]。稀疏编码最早应用于图像的分类中^[40-42],主要通过字典学习的方式得到最优化的基的线性组合,再对初始特征(如 HOG 特征、SIFT 特征等)进行稀疏表达,得到稀疏编码特征,消除初始特征中的冗余成分,提高分类识别效果。在稀疏编码研究中,合适的、显著的字典学习是一项重要研究内容。学习到更具区分性和代表性的字典,可提

高分类精度^[43,44]。

对于激光雷达点云的分类识别而言,也存在特征的冗余问题,可通过特征的稀疏编码方式对其进行稀疏表示,消除冗余特征,得到更加显著的稀疏编码特征。因此,一些学者进行了稀疏编码与激光雷达点云分类的结合研究。Wang等^[14]设计了一种基于矢量量化提取字典的方式,并与LDA相结合,设计了一种点集特征的表达方法;Zhang等^[37]针对矢量量化提取字典显著性不强的缺点,将稀疏编码引入到点特征的构建中,设计了一种点集的SCLDA(Sparse Coding and Latent Dirichlet Allocation)特征;Zhang等^[45]进一步在点的空间和统计特征基础上,将稀疏编码模型引入了标签一致性误差约束项,使训练数据的标签信息参与显著性字典的学习,得到更加稳定的分类识别效果。

为测试稀疏编码特征,本文以机载LiDAR点云为例,对场景2(表1),采用Zhang等^[45]的方法进行验证,并与矢量量化^[12]及深度学习特征^[38]进行对比(表3、图2,彩图见封2)。Zhang等^[45]的方法通过构建多层次对象,并采用显著性字典的方式进行点集稀疏编码特征的表达;矢量量化的方法^[12]在多层次对象的基础上,通过结合BoW(Bag of Words)和LDA表达点集的特征,并采用AdaBoost分类器对未知点云进行分类,字典通过K-means方法训练得到,每个基于点的特征采用矢量量化的方式进行表达,进而聚合成多层次点集特征;深度学习特征^[38]主要通过多层感知机(Multi-Layer Perceptron, MLP)

表3 分类结果的精度/召回率和准确度

Table 3 The precision/recall and accuracy of the classification results

场景2	树木	建筑物	汽车	准确度/%
稀疏编码特征	94.7/94.5	98.1/97.7	53.9/60.5	95.5
矢量量化特征	90.3/93.9	97.6/96.5	49.4/42.0	94.1
深度学习特征	78.2/91.4	90.4/20.1	87.1/12.3	41.3

提取各个点的深度学习特征,并用于点云分类中。由图2和表3的结果可知,稀疏编码特征优于矢量量化特征。此外,由于深度学习特征受训练样本数量的限制,稀疏编码特征在场景2中的分类结果优于基于单点深度学习特征的结果。

由于激光雷达点云数据密集、信息量丰富,稀疏编码具有从大量、繁杂的特征中寻找显著特征的优势,因此,稀疏编码在激光雷达点云的分类识别中效果显著,同时,激光雷达点云与稀疏编码结合的研究仍在不断拓展,如激光雷达点云特征中多层次字典的学习^[46]及度量学习^[47]等。

3 激光雷达点云的多层次对象特征

由于多层次结构能够充分顾及不同空间范围的局部特性,采用多层次特征有利于提高分类识别的效果^[11,48-53]。关于多层次特征的研究主要包括多层次对象的构建、各个层次对象特征的表达及不同层次对象特征的融合等。

3.1 多层次对象的构建

点云对象的构建通过点云的分割实现。首先,无监督模糊聚类的方法被用于点云的平面分割中^[54],该方法可扩展到非平面物体表面形态的识别中。另一种点云分割方法是先将点云转化成深度图后,再借助点云的纹理图像,利用Mean-shift算法^[55]对深度图和纹理图像进行独立分割,然后合并分割结果,得到最终的分割结果。在此研究基础上,为能够得到更好的分割边界和分割区域,Barnea等^[56]对深度图和图像的分割算法进行了改进,设计了一种迭代分割的方法,得到以平面为主的分割结果。之后,Rusu等^[57]通过重采样和去除异常值,对室内的激光雷达点云对象进行分割,该方法可保留橱柜门之间的缝隙,但分割的同时,需要对场景中的地物具有先验知识。在激光雷达点云杆状地物分割提取方面,Yokoyama等^[58]设计了一种基于经验的方法:首先,为突出杆状地物和面状地物,用Laplacian平滑对点云进行收缩处理,再通过聚类的方式,使点云形成杆状、面状及混杂地物,最后,通过一些组合规则对杆状地物进行识别,该方法主要通过人工设计的规则完成点云的分割,在点云自动分割方

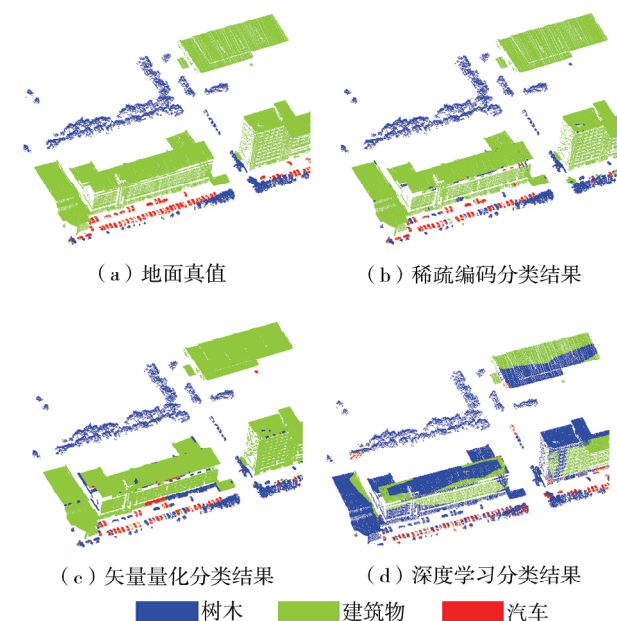


图2 稀疏编码特征、矢量量化特征和深度学习特征分类结果
Fig. 2 The classification results of the sparse coding feature, the vector quantization feature and the deep learning feature

面略有不足。Yu等^[59]设计了一种利用嵌入式模型的点云自动分割方法:对城市地面激光雷达点云中复杂的地表和其他地物点进行分离,利用嵌入式模型进行点云分割,以达到更好的自动分割结果。

3.2 对象特征的表达及融合

许多学者对多层次对象特征的表达进行了研究。例如,Wang等^[14]利用多层次框架处理复杂城市场景的**地面激光扫描(Terrestrial Laser Scanning, TLS)**点云。在此框架内,点云被重采样成不同层次的点集,通过借助LDA对各个层次下的点集特征进行表达,再将每个点集通过分类器进行类别归属判别。Zhang等^[37,45]在上述多层次对象基础上,设计出一种基于指数的多层次点集构建方法,该方法利用SCLDA表达多层次点集特征,分类效果良好。此外,多层次对象特征的构建还可通过不同区域层次特征的结合实现。如Xiong等^[60]将点云数据由粗到细分成多个层次,包括基于点的层次和基于区域的层次,在这种多层次结构中,上一层次的判别结果被用于下一层次,形成结合后的多层次语义特征,再借助统计和关联信息进行点云分类;Xu等^[61]采用3个层次(单点层次、平面分割层次及采用Mean-shift方法分割出的层次)进行点云分类,分别在这3个层次上提取特征进行分割,基于不同层次的融合确定点云的上下文和形状特征。

为验证多层次对象特征对分类结果的影响,本文利用Zhang等^[45]的方法,对场景1和场景2的数据进行测试,得到不同层次数下各类别的 F_1 值^[45](图3)。可以看出,层数的增加能够提高多层次特征的性能,进而提高分类精度,从而证明了多层次特征的显著作用。




图3 点集层数对分类结果的影响
Fig. 3 The influences of the numbers of point cluster layer on classification results

4 激光雷达数据的深度学习特征

深度学习在表达高层次显著特征方面的优势^[15]促进了激光雷达点云特征的构建及分类研究。点云深度特征的构建主要有**多视角方法**^[62-64]、**基于体素转换的方法**^[65,66]和**点云直接转换的方法**^[20,38,67]。

在多视角学习中,通过将三维点云向多个视角投影,得到多个二维投影图像后再进行特征学习。基于体素转换的特征构建主要通过将点云体素化,再提取各体素的特征,以得到激光点的特征。例如,Wu等^[65]设计了一种基于体素的卷积神经网络(Convolutional Neural Networks, CNN)框架,用于表征物体的三维几何形状特征,从而达到高效的识别效果;Maturana等^[66]将基于体素的网格表示方法与三维CNN框架相结合,构建目标的深度学习特征,并采用监督分类方式以提高识别效果。关于**点云直接转换提取深度特征的方式**,主要通过将不规则点云结构转换成规则结构构建深度特征。例如,Qi等^[38]设计了一种直接输入点云的深度神经网络结构,可将不规则的网络结构转换成规则的向量特征,得到的点云具有旋转不变性的深度学习特征,并将其用于基于对象的分类及目标探测中^[67]。本文以机载LiDAR点云为例,采用Qi等^[67]方法进行了深度学习特征的实验,结果(图1d、图2d)表明,该方法比图1b、图1c和图2b、图2c的结果要差,说明训练样本(表1)较少时,不容易构建出稳健的深度学习特征。

综上,基于深度学习特征的雷达点云分类研究已取得了一些研究成果,但由于激光雷达点云中**点分布的不规则性**,尤其制图等应用中点云场景大、数据量多,对其深度学习模型的**训练往往要花费大量时间**,对高效深度学习特征的构建有一定的挑战,因此,点云深度学习特征及深度学习模型的构建研究尚处在起步阶段,存在大量的问题亟待解决。

5 未来研究方向

虽然许多学者对激光雷达点云特征构建及分类做了大量的工作,但仍存在以下问题:**分类的实时性不好、效率不高;没有顾及时空推理对分类的影响**等。激光雷达点云特征表达及分类受计算机视觉、机器学习等领域的推动与影响,在激光雷达点云特征的表达研究方面,呈现以下趋势:1)加强对深度学习的研究与应用。深度学习在表达特征方面已显示出一定的优势^[11],未来将进一步影响激光雷达点云的特征表达,包括大规模场景下的特征学习、存在干扰背景的点云特征学习等。2)迁移学习在激光雷达特征表达方面的研究将不断加强。由于大部分数据采集设备在采集激光雷达点云的同时,也附带了具有丰富纹理信息的影像数据,通过迁移学习的思想可将**影像的纹理信息转换到点云特征上,提高点云特征表达的水平**。3)激光雷达点云**实时特征的构建与在线**

分类研究。目前,自动驾驶及精细化制图需要实时构建特征,对地物进行快速分类、识别与分割;同时,激光雷达点云特征实时构建可满足自动驾驶对精细化地图实时绘制与更新的需要。

6 结论

本文对当前激光雷达点云的特征表达研究进展进行了探索,并借助实验,比较分析了当前基于点的特征和基于对象的特征对分类结果的影响;详细论述了稀疏编码特征的研究现状,并验证了其优势;对激光雷达点云多层次特征的研究现状进行细致评述,并测试验证了多层次特征的显著性能;梳理了激光雷达点云深度学习特征的研究现状,并对激光雷达点云特征及分类的发展趋势进行了分析和预测。通过本文分析可见,点云特征的表达是点云分类识别及结构化表达的基础,对点云分类及目标探测等语义标记至关重要。未来,点云特征的表达也会向显著化、多层次化、多尺度化及异源数据的融合与迁移化(如影像信息与点云特征的融合及迁移)等方向发展,这将会为点云分类识别及结构化表达带来新的突破。

参考文献:

- [1] LANDRIEU L, RAGUET H, VALLET B, et al. A structured regularization framework for spatially smoothing semantic labelings of 3D point clouds[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2017, 132: 102—118.
- [2] 林祥国, 张继贤. 架空输电线路机载激光雷达点云电力线三维重建[J]. 测绘学报, 2016, 45(3): 347—353.
- [3] 尹辉增, 孙轩, 聂振钢. 基于机载激光点云数据的电力线自动提取算法[J]. 地理与地理信息科学, 2012, 28(2): 31—34.
- [4] 刘峰, 龚健雅. 基于 3D LiDAR 数据的城区植被识别研究[J]. 地理与地理信息科学, 2009, 25(6): 5—8.
- [5] 张齐勇, 岑敏仪, 周国清. 城区 LiDAR 点云数据的树木提取[J]. 测绘学报, 2009, 38(4): 330—335.
- [6] 陈卓, 马洪超. 基于机载 LiDAR 数据的大型立交桥自动提取与建模方法[J]. 测绘学报, 2012, 41(2): 252—258.
- [7] 李怡静, 胡翔云, 张剑清, 等. 影像与 LiDAR 数据信息融合复杂场景下的道路自动提取[J]. 测绘学报, 2012, 41(6): 870—876.
- [8] 李卉, 钟成, 黄先锋, 等. 基于空间特性的立交桥自动检测方法[J]. 武汉大学学报(信息科学版), 2012, 37(1): 110—113.
- [9] CHEN X, MA H, WAN J, et al. Multi-view 3D object detection network for autonomous driving[A]. IEEE CVPR[C]. 2017, 1(2): 1907—1915.
- [10] MARKOFF J. Google cars drive themselves, in traffic[EB/OL]. Available: <http://www.nytimes.com/2010/10/10/science/10google.html>. 2010—10—10.
- [11] FARABET C, COUPRIE C, NAJMAN L, et al. Learning hierarchical features for scene labeling[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(8): 1915—1929.
- [12] CHEN D, PEETHAMBARAN J, ZHANG Z. A supervoxel-based vegetation classification via decomposition and modelling of full-waveform airborne laser scanning data[J]. International Journal of Remote Sensing, 2018, 39(9): 2937—2968.
- [13] XU Z, WU L, ZHANG Z. Use of active learning for earthquake damage mapping from UAV photogrammetric point clouds[J]. International Journal of Remote Sensing, 2018, 39(1): 1—28.
- [14] WANG Z, ZHANG L, FANG T, et al. A multiscale and hierarchical feature extraction method for terrestrial laser scanning point cloud classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(5): 2409—2425.
- [15] ANTONARAKIS A S, RICHARDS K S, BRASINGTON J. Object-based land cover classification using airborne LiDAR[J]. Remote Sensing of Environment, 2008, 112(6): 2988—2998.
- [16] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks[A]. European Conference on Computer Vision[C]. Springer International Publishing, 2014. 818—833.
- [17] LOWE D G. Object recognition from local scale-invariant features[A]. Proceedings of the International Conference on Computer Vision[C]. 1999, 2: 1150—1157.
- [18] DALAL N, TRIGGS B. Histograms of oriented gradients for human detection[A]. IEEE Computer Society Conference on Computer Vision and Pattern Recognition[C]. 2005, 1: 886—893.
- [19] ZHANG Y, XU T, MA J. Image categorization using non-negative kernel sparse representation[J]. Neurocomputing, 2017, 269: 21—28.
- [20] ZENG A, SONG S, NIEBNER M, et al. 3DMatch: Learning local geometric descriptors from RGB-D reconstructions[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2017. 199—208.
- [21] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436—444.
- [22] 张继贤, 林祥国, 梁欣廉. 点云信息提取研究进展和展望[J]. 测绘学报, 2017, 46(10): 1460—1469.
- [23] 杨必胜, 梁福逊, 黄荣刚. 三维激光扫描点云数据处理研究进展、挑战与趋势[J]. 测绘学报, 2017, 46(10): 1509—1516.
- [24] WEINMANN M, JUTZI B, HINZ S, et al. Semantic point cloud interpretation based on optimal neighborhoods, relevant features and efficient classifiers[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2015, 105: 286—304.
- [25] WEST K F, WEBB B N, LERSCH J R, et al. Context-driven automated target detection in 3D data[A]. Proceedings of SPIE: Defense and Security[C]. International Society for Optics and Photonics, 2004. 133—143.
- [26] LIN C H, CHEN J Y, SU P L, et al. Eigen-feature analysis of weighted covariance matrices for LiDAR point cloud classification[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2014, 94: 70—79.
- [27] 郭波, 黄先锋, 张帆, 等. 顾及空间上下文关系的 JointBoost 点

- 云分类及特征降维[J]. 测绘学报, 2013, 42(5): 715—721.
- [28] LI Z, ZHANG L, ZHONG R, et al. Classification of urban point clouds: A robust supervised approach with automatically generating training data[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2017, 10(3): 1207—1220.
- [29] PARK J, ZHOU Q Y, KOLTUN V. Colored point cloud registration revisited[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2017. 143—152.
- [30] HEINZEL J, KOCH B. Exploring full-waveform LiDAR parameters for tree species classification[J]. International Journal of Applied Earth Observation and Geoinformation, 2011, 13(1): 152—160.
- [31] NIEMEYER J, MALLET C, ROTTENSTEINER F, et al. Conditional random fields for the classification of LiDAR point clouds[J]. International Archives of Photogrammetry, Remote Sensing and Spatial Information Sciences, 2011, XXXVIII-4/W19: 209—214.
- [32] FROME A, HUBER D, KOLLURI R, et al. Recognizing objects in range data using regional point descriptors[A]. Computer Vision-ECCV[C]. 2004. 224—237.
- [33] LIM E H, SUTER D. Multi-scale conditional random fields for over-segmented irregular 3D point clouds classification[A]. Proceedings of W'08 IEEE Computer Society Conference on Computer Vision and Pattern Recognition[C]. 2008. 1—7.
- [34] LIM E H, SUTER D. 3D terrestrial LiDAR classifications with super-voxels and multi-scale conditional random fields[J]. Computer-Aided Design, 2009, 41(10): 701—710.
- [35] AIJAZI A K, CHECCHIN P, TRASSOUDAIN L. Segmentation based classification of 3D urban point clouds: A super-voxel based approach with evaluation[J]. Remote Sensing, 2009, 5(4): 1624—1650.
- [36] TRUONG-HONG L, LAEFER D F, HINKS T, et al. Combining an angle criterion with voxelization and the flying voxel method in reconstructing building models from LiDAR data[J]. Computer-Aided Civil and Infrastructure Engineering, 2013, 28(2): 112—129.
- [37] ZHANG Z, ZHANG L, TONG X, et al. A multilevel point-cluster-based discriminative feature for ALS point cloud classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(6): 3309—3321.
- [38] QI C R, SU H, MO K, et al. PointNet: Deep learning on point sets for 3D classification and segmentation[A]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)[C]. 2017. 77—85.
- [39] TARIQ U, YANG J, HUANG T S. Multi-view facial expression recognition analysis with generic sparse coding feature[A]. European Conference on Computer Vision[C]. 2012. 578—588.
- [40] TARABALKA Y, CHANUSSOT J, BENEDIKTSSON J A. Segmentation and classification of hyperspectral images using minimum spanning forest grown from automatically selected markers[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics, 2010, 40(5): 1267—1279.
- [41] AHARON M, ELAD M, BRUCKSTEIN A. K-SVD: An algorithm for designing overcomplete dictionaries for sparse representation[J]. IEEE Transactions on Signal Processing, 2006, 54(11): 4311—4322.
- [42] YAGHOUBI M, BLUMENSATH T, DAVIES M E. Dictionary learning for sparse approximations with the majorization method[J]. IEEE Transactions on Signal Processing, 2009, 57(6): 2178—2191.
- [43] JIANG Z, LIN Z, DAVIS L S. Label consistent K-SVD: Learning a discriminative dictionary for recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(11): 2651—2664.
- [44] YANG M, ZHANG L, FENG X, et al. Sparse representation based fisher discrimination dictionary learning for image classification[J]. International Journal of Computer Vision, 2014, 109(3): 209—232.
- [45] ZHANG Z, ZHANG L, TONG X, et al. Discriminative-dictionary-learning-based multilevel point-cluster features for ALS point-cloud classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(12): 7309—7322.
- [46] SHEN L, WANG S, SUN G, et al. Multi-level discriminative dictionary learning towards hierarchical visual categorization[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2013. 383—390.
- [47] WEINBERGER K Q, SAUL L K. Distance metric learning for large margin nearest neighbor classification[J]. Journal of Machine Learning Research, 2009, 10(2): 207—244.
- [48] ZHU Q, LI Y, HU H, et al. Robust point cloud classification based on multi-level semantic relationships for urban scenes[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2017, 129: 86—102.
- [49] BRODU N, LAGUE D. 3D terrestrial LiDAR data classification of complex natural scenes using a multi-scale dimensionality criterion: Applications in geomorphology[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2012, 68: 121—134.
- [50] RAU J Y, JHAN J P, HSU Y C. Analysis of oblique aerial images for land cover and point cloud classification in an urban environment[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(3): 1304—1319.
- [51] YANG B, DONG Z, ZHAO G, et al. Hierarchical extraction of urban objects from mobile laser scanning data[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2015, 99: 45—57.
- [52] YANG B, DONG Z, LIU Y, et al. Computing multiple aggregation levels and contextual features for road facilities recognition using mobile laser scanning data[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2017, 126: 180—194.
- [53] ZHANG Z, ZHANG L, TAN Y, et al. Joint discriminative dictionary learning and classifier for ALS point cloud classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(1): 524—538.

- [54] BIOSCA J M, LERMA J L. Unsupervised robust planar segmentation of terrestrial laser scanner point clouds based on fuzzy clustering methods[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2008, 63: 84—98.
- [55] COMANICIU D, MEER P. Mean shift: A robust approach toward feature space analysis[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2002, 24(5): 603—619.
- [56] BARNEA S, FILIN S. Segmentation of terrestrial laser scanning data using geometry and image information[J]. ISPRS Journal of photogrammetry and Remote Sensing, 2013, 76: 33—48.
- [57] RUSU R B, MARTON Z C, BLODOW N, et al. Towards 3D point cloud based object maps for household environments[J]. Robotics and Autonomous Systems, 2008, 56(11): 927—941.
- [58] YOKOYAMA H, DATE H, KANAI S, et al. Detection and classification of pole-like objects from mobile laser scanning data of urban environments[J]. International Journal of CAD/CAM, 2013, 13(2): 31—40.
- [59] YU Z, XU C, LIU J, et al. Automatic object segmentation from large scale 3D urban point clouds through manifold embedded mode seeking[A]. Proceedings of the 19th ACM International Conference on Multimedia[C]. 2011. 1297—1300.
- [60] XIONG X, MUNOZ D, BAGNELL J A, et al. 3-D scene analysis via sequenced predictions over points and regions[A]. 2011 IEEE International Conference on proceedings of the Robotics and Automation (ICRA)[C]. 2011. 2609—2616.
- [61] XU S, OUDE E S, VOSELMAN G. Entities and features for classification of airborne laser scanning data in urban area[A]. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences[C]. 2012. 257—262.
- [62] PROKHOROV D. A convolutional learning system for object classification in 3-D LiDAR data[J]. IEEE Transactions on Neural Networks, 2010, 21(5): 858—863.
- [63] SU H, MAJI S, KALOGERAKIS E, et al. Multi-view convolutional neural networks for 3D shape recognition[A]. Proceedings of the IEEE International Conference on Computer Vision [C]. 2015. 945—953.
- [64] QI C R, SU H, NIEBNER M, et al. Volumetric and multi-view CNNs for object classification on 3D data[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2016. 648—656.
- [65] WU Z, SONG S, KHOSLA A, et al. 3D shapenets: A deep representation for volumetric shapes[A]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2015. 1912—1920.
- [66] MATURANA D, SCHERER S. Voxnet: A 3D convolutional neural network for real-time object recognition[A]. Intelligent Robots and Systems (IROS), IEEE/RSJ International Conference on IEEE[C]. 2015. 922—928.
- [67] QI C R, YI L, SU H, et al. PointNet++: Deep hierarchical feature learning on point sets in a metric space[A]. Advances in Neural Information Processing Systems[C]. 2017. 5105—5114.

Progress in Research of Feature Representation of Laser Scanning Point Cloud

ZHANG Zhen-xin^{1,2,3}, LIU Yi-bo^{1,2,3}, CHEN Dong⁴, ZHANG Li-qiang⁵, ZHONG Ruo-fei^{1,2,3},

XU Zong-xia^{1,2,3}, HAN You-mei⁶

(1. Beijing Advanced Innovation Center for Imaging Technology, Capital Normal University, Beijing 100048; 2. College of Resources Environment and Tourism, Capital Normal University, Beijing 100048; 3. Key Lab of 3D Information Acquisition and Application, Capital Normal University, Beijing 100048; 4. College of Civil Engineering, Nanjing Forestry University, Nanjing 210037; 5. State Key Laboratory of Remote Sensing Science, School of Geography, Beijing Normal University, Beijing 100875; 6. Beijing Key Laboratory of Urban Spatial Information Engineering, Beijing Institute of Surveying and Mapping, Beijing 100038, China)

Abstract: The feature representation of laser scanning point cloud is the basis of the laser scanning point cloud classification and recognition, and is also the key and hot issue in spatial information science. In this paper, the research progresses of point cloud feature representation are explored. Firstly, some comparison analysis between the point-based and the object-based features is performed. Then, the research situations of the sparse coding feature, the hierarchical feature and the deep learning feature are sorted out. Meanwhile, the merits of the object-based feature, the sparse coding feature, the hierarchical feature and the deep learning feature are deeply analyzed, by means of the experiments. Finally, the trends of feature representation in laser scanning point cloud are pointed. This research can provide some references for the identification and structural expression of LiDAR or other spatial data, and also provide some help for the applications of environmental perception and automatic driving and others.

Key words: laser scanning point cloud; feature representation; sparse coding; deep learning; multi-level; research progress

第 4 页插图

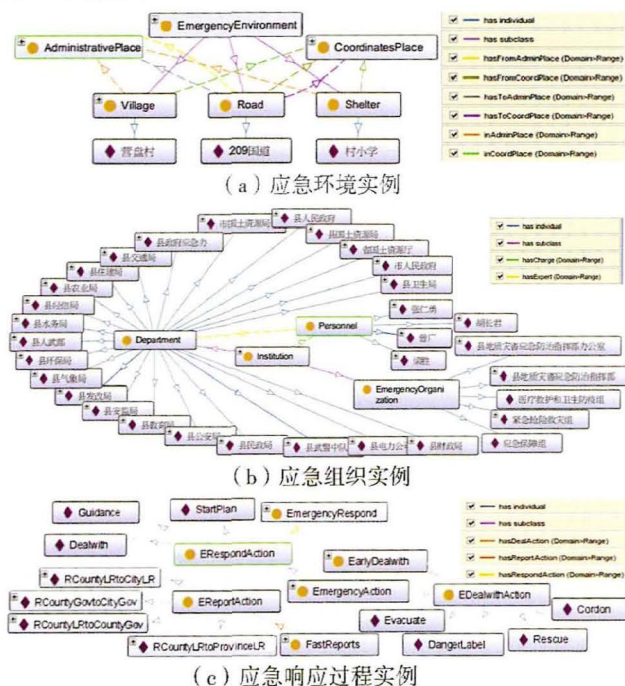


图 2 实体类事实知识实例
Fig. 2 Instance of entity knowledge and emergency action

第 86 页插图




图 4 不同格网尺度下的街道人口相对误差分析
Fig. 4 Error analysis of population estimation at different grid resolution

第 34 页插图

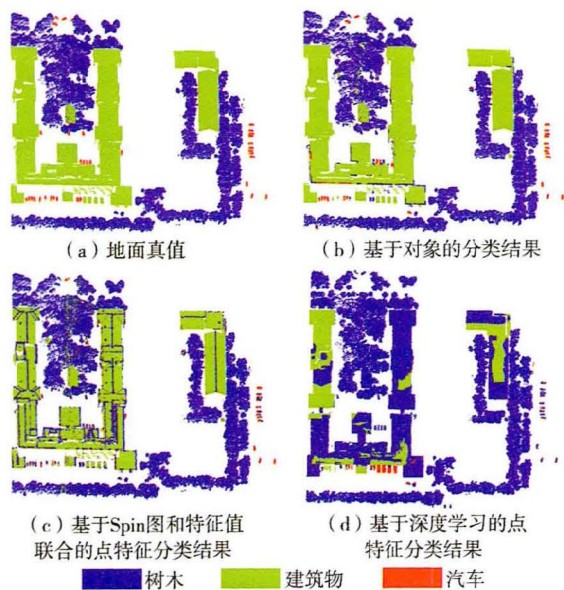


图 1 点特征、对象特征及深度学习特征的分类结果
Fig. 1 The classification results of the point-based feature, object-based feature and deep learning feature

第 35 页插图

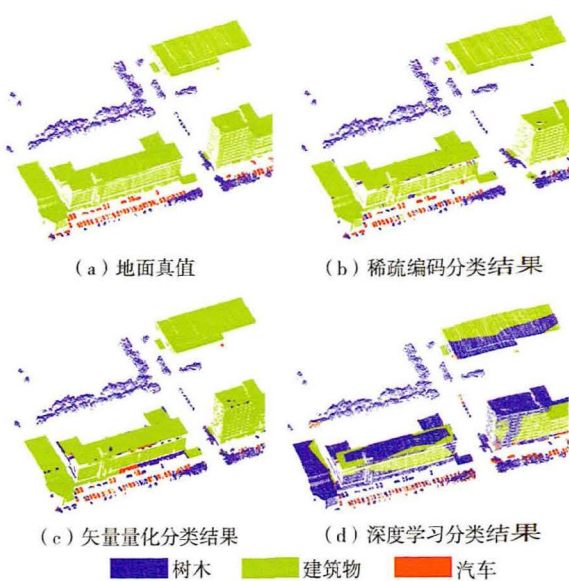


图 2 稀疏编码特征、矢量量化特征和深度学习特征分类结果
Fig. 2 The classification results of the sparse coding feature, the vector quantization feature and the deep learning feature

第 111 页插图

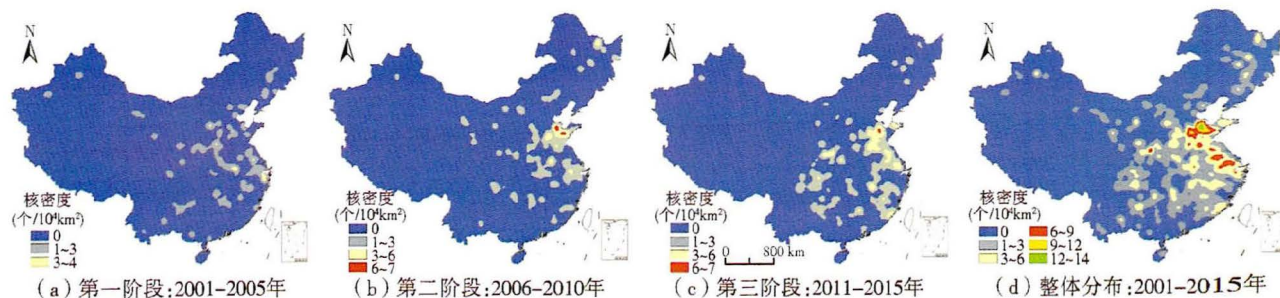


图 2 国家水利风景区核密度分布的时空演变
Fig. 2 Temporal and spatial evolution of spatial density distribution of the National Water Scenic Areas